

EEE933 - Planejamento e Análise de Experimentos

Estudo de Caso 01: Comparação do IMC Médio de Alunos do PPGEE-UFMG

Bernardo Bacha*

Marília Melo[†]

Gustavo Reis[‡]

22 de setembro de 2025

I. Descrição do Problema

Este estudo busca comparar o estilo de vida de alunos de Pós Graduação em Engenharia Elétrica da UFMG, utilizando como valor proxy o Índice de Massa Corporal (IMC) médio dos alunos dos semestres **2016-2** e **2017-2**, reservadas as possibilidades de imprecisão que o índice pode carregar (Nordqvist, 2022).

Além da análise geral, também será feita a comparação separada por gênero (masculino e feminino).

II. Desenho Experimental

O desenho deste estudo de caso é baseado em dados observacionais retrospectivos de peso, altura e gênero da população de interesse. Para tanto, os dados foram filtrados a partir de dois arquivos diferentes e ajustados, rejeitando demais informações dos alunos que não foram consideradas, tais como matrícula e idade do aluno. A partir destes dados é obtida a variável resposta do estudo e setadas a hipótese nula (H_0) e hipótese alternativa (H_1) da análise estatística.

- **População de interesse:** alunos do PPGEE/UFMG.
- **Variável resposta:** $IMC = \text{Peso} / \text{Altura}^2$.
- **Fatores:** semestre (2016-2 vs 2017-2) e sexo (M/F).
- **Hipóteses de teste (bicaudais):**

– $H_0: \mu_{2016-2} = \mu_{2017-2}$

– $H_1: \mu_{2016-2} \neq \mu_{2017-2}$

III. Desenvolvimento

a. Importação e Organização dos Dados

Primeiro, foram importados os dados dos dois semestres (2016-2 e 2017-2), ajustamos o formato, filtramos apenas os dados de alunos da pós-graduação e calculamos o IMC de cada estudante. Depois unimos tudo em um único dataframe.

*PPGEE/UFMG — Relator do experimento - bernardobr@ufmg.br

[†]PPGEE/UFMG — Verificador - mariliamacedomelo@gmail.com

[‡]PPGEE/UFMG — Revisor - augustogustavo94@gmail.com

```
library(dplyr)

# Ler os dados
df_2017 <- read.csv("CS01_20172.csv", sep = ";")
df_2016 <- read.csv("imc_20162.csv")

# Ajustar e calcular IMC
df_2017 <- df_2017 %>%
  rename(Weight.kg = Weight.kg,
         Height.m = height.m,
         Gender = Sex) %>%
  mutate(semestre = "2017-2",
         IMC = Weight.kg / (Height.m^2))

df_2016 <- df_2016 %>%
  filter(Course == "PPGEE") %>%
  mutate(semestre = "2016-2",
         IMC = Weight.kg / (Height.m^2))

# Unir as duas bases
dados <- bind_rows(df_2016, df_2017)

# Resumo rápido
summary(dados$IMC)
```

```
##      Min. 1st Qu.  Median    Mean 3rd Qu.    Max.
##  17.36   20.83   23.26   23.68   25.18   37.55
```

```
table(dados$semestre, dados$Gender)
```

```
##
##           F  M
##  2016-2   7 21
##  2017-2   4 21
```

b. Análise Exploratória

De posse dos dados da variável resposta, busca-se entender como está a distribuição do IMC entre os alunos, comparando os dois semestres e separando por sexo. Para complementar, também apresentamos os resultados no grupo total.

Boxplots


Os boxplots permitem observar a mediana, a dispersão e possíveis outliers do IMC em cada grupo.

```
library(ggplot2)

# Adicionar categoria "Todos"
dados_global <- dados %>%
  mutate(Gender = as.character(Gender)) %>%
  bind_rows(dados %>% mutate(Gender = "Todos"))

# Boxplot
ggplot(dados_global, aes(x = semestre, y = IMC, fill = semestre)) +
```

```
geom_boxplot() +
facet_wrap(~ Gender) +
labs(title = "Distribuição do IMC por semestre (global e por sexo)",
      x = "Semestre", y = "IMC")
```




Histogramas

Já os histogramas mostram como os valores de IMC estão distribuídos dentro de cada grupo, ajudando a verificar se os dados seguem um padrão próximo da normalidade.

```
ggplot(dados_global, aes(x = IMC, fill = semestre)) +
geom_histogram(alpha = 0.6, position = "identity", bins = 15) +
facet_wrap(~ Gender) +
labs(title = "Distribuição do IMC por semestre (global e por sexo)",
      x = "IMC", y = "Frequência")
```

Distribuição do IMC por semestre (global e por sexo)



IV. Análise Estatística


Validação das Premissas

a. Normalidade - Teste de Shapiro-Wilk

Para verificar se os dados seguem uma distribuição normal, combinamos duas abordagens. Primeiro, fizemos uma análise visual com o gráfico QQ-plot para ver se os pontos se distribuíam como o esperado. Em seguida, para uma confirmação estatística, aplicamos o teste de Shapiro-Wilk, que é um método rigoroso e muito recomendado para amostras pequenas.

```
# QQ-plots por semestre x sexo
ggplot(dados, aes(sample = IMC)) +
  stat_qq() +
  stat_qq_line() +
  facet_grid(semestre ~ Gender) +
  labs(title = "QQ-plots do IMC por semestre e sexo")
```

QQ-plots do IMC por semestre e sexo



```
# Shapiro-Wilk por grupo (semestre x sexo)
grupos <- split(dados$IMC, list(dados$semestre, dados$Gender), drop = TRUE)
lapply(grupos, function(x) {
  if (length(x) >= 3 && length(x) <= 5000) shapiro.test(x) else NA
})
```

```
## $`2016-2.F`
##
##  Shapiro-Wilk normality test
##
## data:  x
## W = 0.91974, p-value = 0.4674
##
##
## $`2017-2.F`
##
##  Shapiro-Wilk normality test
##
## data:  x
## W = 0.7475, p-value = 0.03659
##
##
## $`2016-2.M`
##
##  Shapiro-Wilk normality test
##
## data:  x
## W = 0.92833, p-value = 0.1275
##
##
## $`2017-2.M`
```

```
##
## Shapiro-Wilk normality test
##
## data:  x
## W = 0.96494, p-value = 0.6206
```

Resultados - Shapiro-Wilk:

- 2016-2 Feminino: $p = 0.4674$
- 2017-2 Feminino: $p = 0.0366$
- 2016-2 Masculino: $p = 0.1275$
- 2017-2 Masculino: $p = 0.6206$

Nota: o grupo feminino de 2017-2 tem $n = 4$. Com tamanhos tão pequenos, testes de normalidade ficam instáveis e sensíveis a um único valor. O resultado é registrado, mas será complementado com análise não-paramétrica na próxima subseção. Portanto, embora o teste de Shapiro-Wilk sugira uma violação da premissa de normalidade, esse resultado deve ser interpretado com cautela devido à baixa amostra. Essa sensibilidade do teste com $n=4$ reforça a necessidade de complementar a análise com abordagens não-paramétricas ou testes robustos como o de Welch, que é menos sensível a desvios da normalidade.

b. Homogeneidade de Variâncias - Teste de Fligner-Killeen

Para avaliar a premissa de homogeneidade de variâncias, foi utilizado o teste de Fligner-Killeen. A escolha deste teste se justifica por sua robustez a possíveis desvios da normalidade, uma consideração importante, visto que a normalidade da amostra do grupo feminino foi questionada na análise anterior. A hipótese nula do teste é de que as variâncias do IMC são iguais entre os semestres.

```
fligner.test(IMC ~ semestre, data = subset(dados, Gender == "M"))
```

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data:  IMC by semestre
## Fligner-Killeen:med chi-squared = 0.082824, df = 1, p-value = 0.7735
```

```
fligner.test(IMC ~ semestre, data = subset(dados, Gender == "F"))
```

```
##
## Fligner-Killeen test of homogeneity of variances
##
## data:  IMC by semestre
## Fligner-Killeen:med chi-squared = 0.71101, df = 1, p-value = 0.3991
```

Resultados - Fligner-Killeen:

- Masculino: $p = 0.7735$
- Feminino: $p = 0.3991$

Os resultados não indicaram evidências para rejeitar essa hipótese, com um p-valor de 0.7735 para o grupo masculino e 0.3991 para o feminino. Portanto, conclui-se que as variâncias podem ser consideradas homogêneas entre os semestres para ambos os sexos.

c. Teste de Hipóteses - Testes t - Welch e Student

Para comparar as médias de IMC entre os semestres **2016-2** e **2017-2**, separadamente para homens e mulheres, o método principal adotado foi o **teste t de Welch para duas amostras independentes**, com um nível de significância de $\alpha = 0,05$. A preferência por este teste segue as recomendações da literatura estatística para garantir a robustez da análise. Conforme demonstrado em estudos clássicos como o de Moser e Stevens (1992), a prática de realizar um teste preliminar de variâncias para então decidir qual teste t utilizar pode aumentar a taxa de erro do tipo I. Desta forma, o teste de Welch se apresenta como uma alternativa mais segura. Ainda assim, para fins de uma análise comparativa completa, o teste t de Student (`var.equal = TRUE`) também foi executado para que os resultados de ambos os métodos pudessem ser avaliados.

```
# --- Grupo Masculino ---
```

```
print("---- Homens: Teste de Welch (var.equal = FALSE) ----")
```

```
## [1] "---- Homens: Teste de Welch (var.equal = FALSE) ----"
```

```
t.test(IMC ~ semestre, data = subset(dados, Gender == "M"), var.equal = FALSE)
```

```
##
##  Welch Two Sample t-test
##
## data:  IMC by semestre
## t = 0.53979, df = 38.057, p-value = 0.5925
## alternative hypothesis: true difference in means between group 2016-2 and group 2017-2 is
##    ↪ not equal to 0
## 95 percent confidence interval:
## -1.788823  3.089716
## sample estimates:
## mean in group 2016-2 mean in group 2017-2
##          24.93595          24.28551
```

```
print("---- Homens: Teste de Student (var.equal = TRUE) ----")
```

```
## [1] "---- Homens: Teste de Student (var.equal = TRUE) ----"
```

```
t.test(IMC ~ semestre, data = subset(dados, Gender == "M"), var.equal = TRUE)
```

```
##
##  Two Sample t-test
##
## data:  IMC by semestre
## t = 0.53979, df = 40, p-value = 0.5923
## alternative hypothesis: true difference in means between group 2016-2 and group 2017-2 is
##    ↪ not equal to 0
## 95 percent confidence interval:
## -1.784943  3.085836
## sample estimates:
## mean in group 2016-2 mean in group 2017-2
##          24.93595          24.28551
```

```
# --- Grupo Feminino ---
```

```
print("---- Mulheres: Teste de Welch (var.equal = FALSE) ----")
```

```
## [1] "---- Mulheres: Teste de Welch (var.equal = FALSE) ----"
```

```
t.test(IMC ~ semestre, data = subset(dados, Gender == "F"), var.equal = FALSE)

##
## Welch Two Sample t-test
##
## data: IMC by semestre
## t = 2.17, df = 8.5966, p-value = 0.0595
## alternative hypothesis: true difference in means between group 2016-2 and group 2017-2 is
##   ↪ not equal to 0
## 95 percent confidence interval:
## -0.1318507  5.4075232
## sample estimates:
## mean in group 2016-2 mean in group 2017-2
##          21.08443          18.44660

print("--- Mulheres: Teste de Student (var.equal = TRUE) ---")

## [1] "--- Mulheres: Teste de Student (var.equal = TRUE) ---"

t.test(IMC ~ semestre, data = subset(dados, Gender == "F"), var.equal = TRUE)
```

```
##
## Two Sample t-test
##
## data: IMC by semestre
## t = 1.9308, df = 9, p-value = 0.08556
## alternative hypothesis: true difference in means between group 2016-2 and group 2017-2 is
##   ↪ not equal to 0
## 95 percent confidence interval:
## -0.4527037  5.7283762
## sample estimates:
## mean in group 2016-2 mean in group 2017-2
##          21.08443          18.44660
```

Resultados - Testes de hipóteses:

A análise dos testes de hipóteses não apontou diferença estatisticamente significativa no IMC médio para nenhum dos grupos ao nível de $\alpha = 0,05$. Para o grupo masculino, os resultados do teste de Welch ($p = 0.5925$) e do teste de Student ($p = 0.5923$) foram praticamente idênticos, não indicando alteração entre os semestres. Já para o grupo feminino, os p-valores divergiram: o teste de Welch apresentou um resultado marginalmente significativo ($p = 0.0595$), mais próximo do limiar de significância que o do teste de Student ($p = 0.08556$). Essa comparação reforça a robustez do teste de Welch que, apesar de não atingir a significância formal, capturou uma tendência mais forte nos dados do grupo feminino.

d. Tamanho do Efeito e Poder Estatístico

Após a análise de hipóteses, que avalia a significância estatística, a investigação foi aprofundada em duas frentes para uma interpretação completa dos resultados. A primeira foi quantificar a magnitude prática da diferença observada, o que é feito através do cálculo do **tamanho do efeito** (utilizando o g de Hedges, por ser mais preciso para amostras pequenas conforme demonstrado por Hedges e Olkin (1985)). A segunda foi avaliar a capacidade do estudo em detectar um efeito, caso ele realmente exista, o que é medido pela análise de **poder estatístico**. A análise conjunta dessas duas métricas é o que permite contextualizar os p-valores e entender cenários complexos, como um efeito de grande magnitude que não atinge significância estatística devido ao baixo poder do teste.


```

# Carregar pacotes necessários
# Se não tiver instalado, rode no console: install.packages(c("effsize", "pwr"))
library(effsize)
library(pwr)

# ---- Tamanho do Efeito (g de Hedges) ----

print("---- Tamanho do Efeito | Homens ----")

## [1] "---- Tamanho do Efeito | Homens ----"

cohen.d(IMC ~ semestre, data = subset(dados, Gender == "M"),
        hedges.correction = TRUE)

##
## Hedges's g
##
## g estimate: 0.16344 (negligible)
## 95 percent confidence interval:
##      lower      upper
## -0.4495299  0.7764100

print("---- Tamanho do Efeito | Mulheres ----")

## [1] "---- Tamanho do Efeito | Mulheres ----"

cohen.d(IMC ~ semestre, data = subset(dados, Gender == "F"),
        hedges.correction = TRUE)

##
## Hedges's g
##
## g estimate: 1.106459 (large)
## 95 percent confidence interval:
##      lower      upper
## -0.2786636  2.4915825

# ---- Análise de Poder Estatístico ----

# Poder para o grupo MASCULINO (n1=21, n2=21, d=0.16)
print("---- Poder Estatístico | Homens ----")

## [1] "---- Poder Estatístico | Homens ----"

pwr.t2n.test(n1 = 21, n2 = 21, d = 0.16, sig.level = 0.05, alternative = "two.sided")

##
##      t test power calculation
##
##      n1 = 21
##      n2 = 21
##      d = 0.16
##      sig.level = 0.05
##      power = 0.07982448
##      alternative = two.sided

```

```

# Poder para o grupo FEMININO (n1=7, n2=4, d=1.11)
print("--- Poder Estatístico | Mulheres ---")

## [1] "--- Poder Estatístico | Mulheres ---"

pwr.t2n.test(n1 = 7, n2 = 4, d = 1.11, sig.level = 0.05, alternative = "two.sided")

##
##      t test power calculation
##
##          n1 = 7
##          n2 = 4
##          d = 1.11
##      sig.level = 0.05
##          power = 0.3534739
##      alternative = two.sided

# ---- Cálculo de amostra para potência de 80%

power.t.test(power = 0.8,      # potência desejada
             delta = 0.5,      # tamanho do efeito esperado (diferença entre médias)
             sd = 1,           # desvio padrão estimado
             sig.level = 0.05,
             type = "two.sample", # tipo do teste
             alternative = "two.sided") # bilateral

##
##      Two-sample t test power calculation
##
##          n = 63.76576
##          delta = 0.5
##          sd = 1
##      sig.level = 0.05
##          power = 0.8
##      alternative = two.sided
##
## NOTE: n is number in *each* group

```

Resultados - Tamanho do Efeito e Poder Estatístico:

A análise do tamanho do efeito e do poder estatístico revela cenários distintos para os dois grupos. Para o grupo masculino, foi observado um efeito de magnitude desprezível ($g = 0.16$), com um poder estatístico de apenas 8% para detectá-lo, o que é consistente com o resultado não-significativo do teste t. Em contraste, para o grupo feminino, a magnitude do efeito foi classificada como grande ($g = 1.11$). No entanto, a análise de poder indicou que o estudo tinha apenas 35% de chance de detectar um efeito dessa magnitude como estatisticamente significativo. Isso explica o resultado marginal do teste t ($p = 0.0595$): embora a diferença observada seja grande na prática, o estudo não teve poder suficiente para confirmá-la estatisticamente devido à amostra reduzida.

V. Discussão e Conclusões

- Ao analisar estatisticamente o grupo completo, não observou-se diferença significativa no IMC entre os semestres avaliados. Notou-se também que unir os dois gêneros em um único grupo poderia levar a uma inferência incorreta. Já a análise estratificada por gênero trouxe à tona um problema que antes estava oculto: a falta de dados para a categoria feminina em 2017. A categoria feminina em 2017 apresentou déficit de amostras, causando prejuízo ao processo de inferência estatística.

- Após a estratificação por gênero, tanto para as amostras menores (gênero feminino), quanto para amostras maiores (gênero masculino), os testes apresentaram baixa potência, inferior a 80%, o que sugere que seriam fracos para detectar diferenças reais e consequentemente possuem baixa confiabilidade de rejeitar corretamente a hipótese nula. Em futuras análises, para testes de potência superior a 80%, seria necessária uma amostragem mais robusta, com grupos de ao menos 64 amostras.

VI. Referências

Why BMI is inaccurate and misleading. Christian Nordqvist, Medical News Today, 2022. Disponível em: <https://www.medicalnewstoday.com/articles/265215>. Acesso em: 18 set. 2025.

MOSER, B. K.; STEVENS, G. R. Homogeneity of Variance in the Two-Sample Means Test. **The American Statistician**, v. 46, n. 1, p. 19-22, fev. 1992.

HEDGES, Larry V.; OLKIN, Ingram. **Statistical methods for meta-analysis**. Orlando: Academic Press, 1985.